

使用 replace() 函数将 DataFrame 中所有的 ? 替换为 np.nan

完整代码示例

代码块

```
1  import pandas as pd
2  import numpy as np
3
4  # 创建包含 '?' 的示例 DataFrame
5  data = {
6      '姓名': ['张三', '李四', '王五', '?'],
7      '年龄': [25, '?', 28, 30],
8      '城市': ['北京', '上海', '?', '广州'],
9      '成绩': ['?', 85, 90, '?']
10 }
11
12 df = pd.DataFrame(data)
13
14 print("替换前的 DataFrame:")
15 print(df)
16 print("\n数据类型:")
17 print(df.dtypes)
18 print()
19
20 # ===== 方法1: 全局替换 (推荐) =====
21 df_replaced = df.replace('?', np.nan)
22
23 print("方法1 - 替换后的 DataFrame:")
24 print(df_replaced)
25 print("\n数据类型:")
26 print(df_replaced.dtypes)
27 print()
28
29 # 验证替换结果
30 print("检查是否还有 '?' :")
31 print((df_replaced == '?').any().any()) # 应该输出 False
32 print()
33
```

```

34 print("检查 NaN 数量:")
35 print(df_replaced.isnull().sum())
36 print()
37
38 # ===== 方法2: 原地替换 (修改原DataFrame) =====
39 df2 = df.copy()
40 df2.replace('?', np.nan, inplace=True)
41
42 print("方法2 - 原地替换后的 DataFrame:")
43 print(df2)
44 print()
45
46 # ===== 方法3: 针对特定列替换 =====
47 df3 = df.copy()
48 df3['年龄'] = df3['年龄'].replace('?', np.nan)
49 df3['成绩'] = df3['成绩'].replace('?', np.nan)
50
51 print("方法3 - 特定列替换后的 DataFrame:")
52 print(df3)
53 print()
54
55 # ===== 方法4: 同时替换多个值 =====
56 df4 = df.copy()
57 df4.replace(['?', 'N/A', 'null', '-'], np.nan, inplace=True)
58
59 print("方法4 - 替换多个特殊值的 DataFrame:")
60 print(df4)
61 print()

```

实际应用场景示例

代码块

```

1 import pandas as pd
2 import numpy as np
3
4 # 模拟真实数据场景: 从CSV读取的数据可能包含 '?'
5 data = {
6     '用户ID': [1, 2, 3, 4, 5],
7     '姓名': ['张三', '李四', '?', '王五', '赵六'],
8     '年龄': [25, '?', 30, '?', 28],

```

```
9     '收入': ['?', 5000, 8000, '?', 6000],
10     '职业': ['工程师', '?', '教师', '医生', '?']
11 }
12
13 df = pd.DataFrame(data)
14
15 print("="*60)
16 print("原始数据（包含 '?' 缺失值标记）")
17 print("="*60)
18 print(df)
19 print()
20
21 # 将所有 '?' 替换为 np.nan
22 df_clean = df.replace('?', np.nan)
23
24 print("="*60)
25 print("清洗后的数据（'?' 已替换为 NaN）")
26 print("="*60)
27 print(df_clean)
28 print()
29
30 # 查看每列的缺失值统计
31 print("="*60)
32 print("缺失值统计")
33 print("="*60)
34 print(df_clean.isnull().sum())
35 print()
36
37 # 计算数值列的平均值（自动忽略NaN）
38 print("="*60)
39 print("数值列统计信息")
40 print("="*60)
41 print(df_clean[['年龄', '收入']].describe())
42 print()
43
44 # 填充缺失值（可选操作）
45 df_filled = df_clean.copy()
46 df_filled['年龄'] = df_filled['年龄'].fillna(df_filled['年龄'].mean())
47 df_filled['收入'] = df_filled['收入'].fillna(df_filled['收入'].mean())
48
49 print("="*60)
50 print("用均值填充缺失值后的数据")
51 print("="*60)
52 print(df_filled)
```



处理混合数据类型的注意事项

代码块

```
1  import pandas as pd
2  import numpy as np
3
4  # 注意：如果列中包含混合类型，可能需要先转换类型
5  data = {
6      'A': [1, 2, '?', 4],
7      'B': ['a', '?', 'c', 'd'],
8      'C': [1.5, 2.5, '?', 4.5]
9  }
10
11 df = pd.DataFrame(data)
12
13 print("原始数据:")
14 print(df)
15 print("\n原始数据类型:")
16 print(df.dtypes)
17 print()
18
19 # 替换 '?'
20 df_replaced = df.replace('?', np.nan)
21
22 print("替换后:")
23 print(df_replaced)
24 print("\n替换后数据类型:")
25 print(df_replaced.dtypes)
26 print()
27
28 # 如果需要，可以将数值列转换为正确的类型
29 df_converted = df_replaced.copy()
30 df_converted['A'] = pd.to_numeric(df_converted['A'], errors='coerce')
31 df_converted['C'] = pd.to_numeric(df_converted['C'], errors='coerce')
32
33 print("类型转换后:")
34 print(df_converted)
35 print("\n转换后数据类型:")
36 print(df_converted.dtypes)
```

关键点总结

1. 基本语法

代码块

```
1  # 返回新DataFrame
2  df_new = df.replace('?', np.nan)
3
4  # 原地修改
5  df.replace('?', np.nan, inplace=True)
```

2. 常用参数

代码块

```
1  df.replace(
2      to_replace='?',      # 要替换的值
3      value=np.nan,        # 替换成的值
4      inplace=False,       # 是否原地修改
5      regex=False          # 是否使用正则表达式
6  )
```

3. 批量替换多个值

代码块

```
1  # 同时替换多个特殊标记
2  df.replace(['?', 'N/A', 'null', '-', ''], np.nan, inplace=True)
```

4. 使用正则表达式

代码块

```
1 # 替换所有空白字符串
2 df.replace(r'^\s*$', np.nan, regex=True, inplace=True)
```

5. 验证替换结果

代码块

```
1 # 检查是否还有 '?'
2 print((df == '?').any().any())
3
4 # 查看缺失值数量
5 print(df.isnull().sum())
6
7 # 查看缺失值比例
8 print(df.isnull().mean() * 100)
```

⚠ 常见问题

Q: 替换后数据类型不对怎么办?

代码块

```
1 # 使用 pd.to_numeric 强制转换
2 df['列名'] = pd.to_numeric(df['列名'], errors='coerce')
```

Q: 如何只替换特定列的 '?'?

代码块

```
1 df[['列1', '列2']] = df[['列1', '列2']].replace('?', np.nan)
```

Q: 替换后想删除含有NaN的行?

代码块

```
1 df_clean = df.replace('?', np.nan).dropna()
```

这样就可以成功将 DataFrame 中所有的 `?` 替换为 `np.nan`，方便后续的数据清洗和分析！